Taller 2: Redes Neuronales

Jeferson Camio Runza Olaya
Paula Andrea Blando Ramirez
Karol Dayana Bedoya Olivar

Universidad ECCI
Departamento de ingeniería
ingeniería Industrial
Sistemas Avanzados de Producción

Tabla de Contenido

Introducción 3

Fase 1: Desarrollo Analítico: Regularización Ridge. 5

Fase 2: Optimización y Descenso de Gradiente 9

Definición del Entorno de Experimentación 9

A. Variación de la Tasa de Aprendizaje (Learning Rate - n) 9

B. Variación del Punto de Inicio (Sensibilidad a la Inicialización) 12

Análisis de la Topografía y Convergencia 13

A. El fenómeno de “Overshooting” 13

Fase 3: Predicción de Demanda mediante Redes Neuronales (MLP) 15

Propuesta: Redes Neuronales (MLP) 16

Precisión y Correlación (Predicho vs. Real) 16

Distribución de Errores (Histograma de Residuales) 17

Convergencia del Aprendizaje (Curva de Pérdida) 18

Evaluación del Modelo (GridSearchCV) 18

Predicciones vs. Valores Reales 20

Fase 4: Propagación hacia Adelante (Forward Propagation) Manual 26

Fase 5: Evaluación de Modelos y Toma de Decisiones (Caso: Mantenimiento Predictivo) 29

1. Análisis del Peso de Clase (class_weight) 29

2. La Trampa de la Exactitud (Accuracy Trap) 29

Interpretación de la Matriz de Confusión: 30

Tabla de Ilustraciones

Ilustración 1 Trayectoria del Descenso de Gradiente en función de costo 10
Ilustración 2. Resultado final del Descenso de Gradiente en la función de costo..... 10
Ilustración 3 Dinámica de la trayectoria del Descenso de Gradiente sobre la superficie de error..... 11
Ilustración 4 Comportamiento del Descenso de Gradiente con saltos excesivos en la función de costo..... 11
Ilustración 5 Trayectoria del Descenso de Gradiente hacia el punto óptimo en la función de costo 12
Ilustración 6 Trayectoria del Descenso de Gradiente hacia un mínimo local..... 12
Ilustración 7 Análisis de predicción y residuos del modelo..... 15
Ilustración 8 Clasificación con perceptrón sin bias y su restricción geométrica..... 16
Ilustración 9 Evaluación del MLPRegressor: relación entre valores reales y predicciones (Train vs Test) 17
Ilustración 10 Análisis de la distribución de errores (residuales) del MLPRegressor..... 17
Ilustración 11 Convergencia del modelo MLP: evolución de la función de pérdida (loss) en entrenamiento 18
Ilustración 12 Evaluación del mejor modelo MLP tras optimización de hiperparámetros: ajuste entre valores reales y predichos en test 22
Ilustración 13 Análisis de la distribución de errores del mejor MLPRegressor tras optimización de hiperparámetros..... 23
Ilustración 14 Curva de pérdida del MLP optimizado: análisis de convergencia en entrenamiento 23

Tabla de Tablas

Tabla 1 Comparativa de Coeficientes de Determinación (R2)..... 24

Introducción

En el contexto actual de las ciudades inteligentes y la movilidad sostenible, los sistemas de bicicletas compartidas han evolucionado más allá de ser un simple medio de transporte, convirtiéndose en una fuente valiosa de información para la toma de decisiones operativas. La predicción de la demanda en este tipo de sistemas representa un desafío importante, ya que depende no solo de factores temporales, sino también de variables externas como las condiciones climáticas y el comportamiento de los usuarios.

El presente trabajo tiene como objetivo aplicar diferentes técnicas de analítica y aprendizaje automático para modelar y predecir la demanda de bicicletas, así como analizar el comportamiento de modelos más complejos en contextos reales. Para ello, se abordan diversas fases que incluyen desde el desarrollo analítico de la regresión Ridge, hasta la implementación y optimización de redes neuronales tipo Perceptrón Multicapa (MLP), pasando por el análisis del algoritmo de descenso de gradiente y su impacto en la convergencia de los modelos.

A lo largo del desarrollo, no solo se busca obtener resultados numéricos, sino también interpretar los modelos desde una perspectiva técnica y de negocio, evaluando su desempeño mediante métricas como MAE, RMSE, R^2, Recall y Precision. Este enfoque permite entender cómo las herramientas de analítica avanzada pueden contribuir a mejorar la eficiencia operativa, reducir costos y apoyar la toma de decisiones en entornos industriales y de servicios.

Finalmente, el trabajo integra tanto fundamentos matemáticos como experimentación computacional, evidenciando la importancia de seleccionar adecuadamente los modelos y sus hiperparámetros para lograr soluciones robustas y aplicables en escenarios reales.

Fase 1: Desarrollo Analítico: Regularización Ridge.

$$J(\beta) = \sum_{i=1}^{n} \left(y_i - \beta_0 - \sum_{j=1}^{p} \beta_j x_{ij} \right)^2 + \lambda \sum_{j=1}^{p} \beta_j^2$$

Definiciones

$X \in \mathbb{R}^{n \times p}$: Matriz de diseño
$y \in \mathbb{R}^{n \times 1}$: Vector de respuestas
$\beta \in \mathbb{R}^{p \times 1}$: Vector de parametros
$\lambda \geq 0$: Parametros de regularización
$I \in \mathbb{R}^{p \times p}$: Matriz identidad

Error cuadratico residual

$$(y - X\beta)^T (y - X\beta)$$

Termino penalización

$$\lambda \beta^T \beta$$

$$J(\beta) = (y - X\beta)^T (y - X\beta) + \lambda \beta^T \beta$$

2. Expansión de la forma cuadratica:

$$(y - X\beta)^T (y - X\beta)$$

$$y^T y - y^T X\beta - (X\beta)^T y + (X\beta)^T X\beta$$

$$(y - X\beta)^T (y - X\beta) = y^T y - y^T X\beta - \beta^T X^T y + \beta^T X^T X\beta$$

$$(y - X\beta)^T (y - X\beta) = y^T y - 2\beta^T X^T y + \beta^T X^T X\beta$$

Añadimos penalización

$$J(\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T X^T X \beta + \lambda \beta^T \beta$$

Agrupamos los terminos cuadraticos en β

$$J(\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T (X^T X + \lambda I) \beta$$

3 Condición de Primer orden

Derivamos $J(\beta)$ respecto a β

$$J(\beta) = Y^T Y - 2\beta^T X^T Y + \beta^T (X^T X + \lambda I) \beta$$

$$\frac{\partial J(\beta)}{\partial \beta} = -2X^T Y + 2(X^T X + \lambda I)\beta$$

Igualamos al vector nulo

$$-2X^T Y + 2(X^T X + \lambda I)\beta = 0$$

$$\frac{-\cancel{2}X^T Y + \cancel{2}(X^T X + \lambda I)\beta}{\cancel{2}} = -X^T Y + (X^T X + \lambda I)\beta$$

$$\hookrightarrow (X^T X + \lambda I)\beta = X^T Y$$

4 Solución cerrada

Ahora despejamos β:

$$\beta = (X^T X + \lambda I)^{-1} X^T Y$$

$$\beta_{Ridge} = (X^T X + \lambda I)^{-1} X^T Y$$

¿Por qué la suma de λI garantiza que la matriz resultante sea invertible incluso si XT X es singular (no invertible)?

En algunos casos, la matriz $X^T X$ no se puede invertir. Esto ocurre cuando existe multicolinealidad, es decir, cuando algunas variables estan muy relacionadas entre si o son combinaciones de otras.

Cuando esto pasa el modelo de regresion tradicional no puede encontrar una solución unica o estable. Para solucionar esto, la regresión ridge agrega un termino λI a la matriz.

$$X^T X + \lambda I$$

Este termino suma un valor positivo (λ) en la diagonal de la matriz.

- Elimina valores propios iguales a cero.
- Hacer que todos los valores propios sean positivos.
- Garantizar que la matriz sea invertible.

¿Qué sucede con el modelo y sus coeficientes cuando λ → 0?

Cuando el valor de λ se acerca a 0, el termino de penalización desaparece

En ese caso la formula de Ridge se convierte en:

$$\hat{\beta} = (X^T X)^{-1} X^T y$$

Sesgo bajo
Varianza alta

- El modelo no tiene ninguna restricción sobre los coeficientes.
- Intenta ajustarse lo mejor posible a los datos
- Puede volverse muy sensible a los datos de entrenamiento.

El modelo aprende demasiado de los datos y puede perder capacidad de generalizar.

¿Y qué ocurre cuando $\lambda \to \infty$?

Cuando λ es muy grande, el termino de penalización domina la función de costo.

Esto hace que el modelo trate de minimizar los coeficientes llevandolos hacia cero:

$$\beta_j \approx 0$$

Sesgo Alto
Varianza baja

- Las variables pierden influencia
- El modelo se vuelve muy simple
- La predicción se acerca a un valor constante

El modelo se vuelve demasiado simple y deja de aprender del problema.

Fase 2: Optimización y Descenso de Gradiente

Definición del Entorno de Experimentación

Para entender cómo aprende una red neuronal, se utilizó la Función de Himmelblau como superficie de error. Esta función es ideal para pruebas de optimización debido a que posee cuatro mínimos locales, lo que permite evaluar si el algoritmo queda atrapado en soluciones subóptimas o si logra converger al mínimo global dependiendo de su configuración.

Tareas de Experimentación y Observaciones

A. Variación de la Tasa de Aprendizaje (Learning Rate - n)

La tasa de aprendizaje define el tamaño del paso en la dirección opuesta al gradiente. Se observaron los siguientes comportamientos críticos:

Tasa de Aprendizaje (Learning Rate = 0.0001)

- Observación Visual: Se visualiza una trayectoria de línea roja continua y rectilínea. El punto se desplaza de forma estable hacia el mínimo, pero la longitud de la trayectoria es corta, cubriendo apenas una fracción del camino hacia el centro del valle.
- Diagnóstico: Convergencia lenta. El algoritmo ha identificado la dirección correcta del descenso, pero el tamaño del paso es excesivamente conservador para el relieve de la función de Himmelblau.
- Interpretación Crítica: Este caso representa un equilibrio de alta estabilidad, pero baja eficiencia computacional. Aunque el modelo llegará eventualmente al mínimo sin oscilaciones, requeriría un número de iteraciones significativamente mayor (probablemente >10,000), lo que en modelos reales como el de Bikeshare se traduciría en tiempos de entrenamiento innecesariamente largos y costosos.

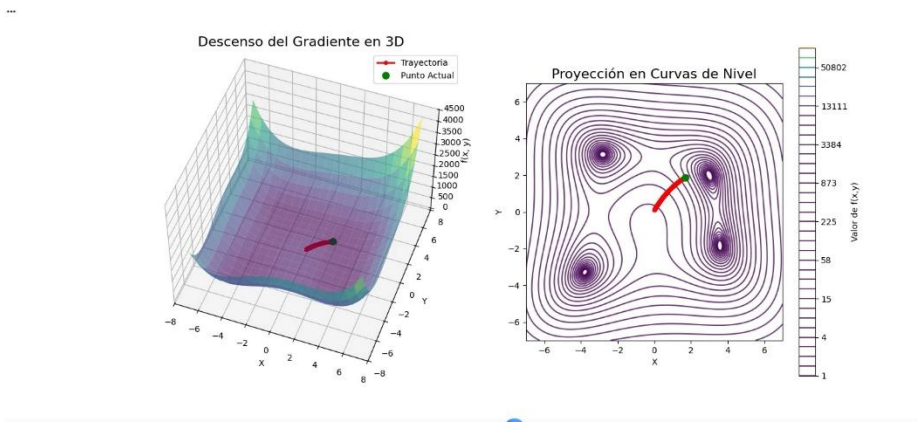

Ilustración 1 Trayectoria del Descenso de Gradiente en función de costo

Tasa de Aprendizaje Insuficiente (n= 1e-7):

- Observación: El punto permanece prácticamente estático en la ladera de la función.
- Interpretación: Aunque el algoritmo realiza 1000 iteraciones, el avance es insignificante. Esto demuestra que una tasa demasiado baja hace que el entrenamiento sea computacionalmente inviable.

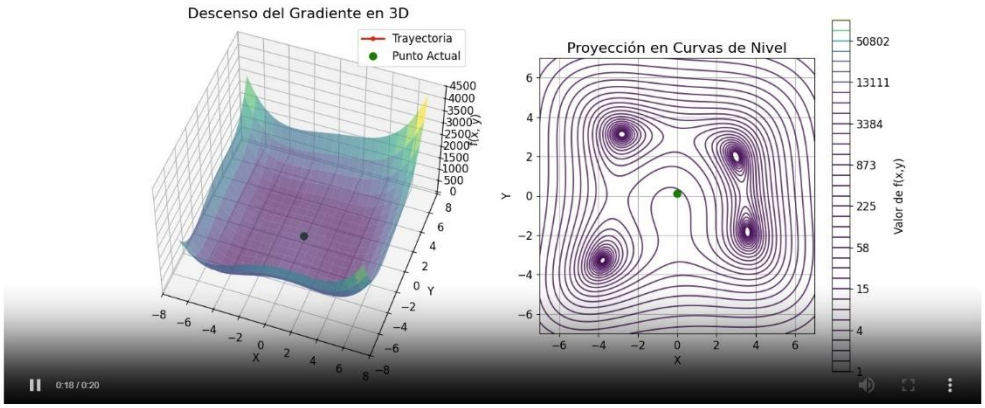

Ilustración 2. Resultado final del Descenso de Gradiente en la función de costo

Tasa de Aprendizaje Excesiva (n= 1.0):

- Observación: La trayectoria se sale de los límites de la gráfica inmediatamente.

- Interpretación: Se presenta el fenómeno de divergencia. El paso es tan grande que "sobrepasa" el mínimo y aterriza en una zona de mayor error, creando un bucle de retroalimentación positiva que dispara el error al infinito.

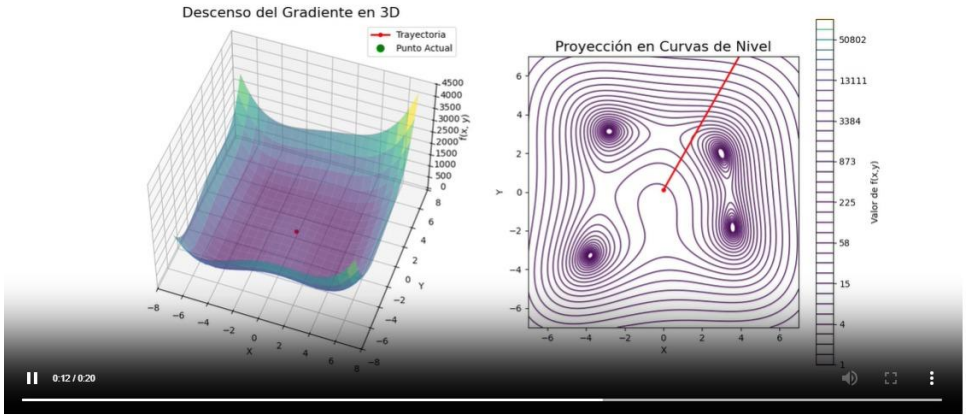

Ilustración 3 Dinámica de la trayectoria del Descenso de Gradiente sobre la superficie de error

Tasa de Aprendizaje Óptima (n= 0.0005):

- Observación: Una línea suave y directa hacia el centro de uno de los valles.
- Interpretación: Existe un equilibrio donde el algoritmo es lo suficientemente rápido para avanzar y lo suficientemente estable para no oscilar.

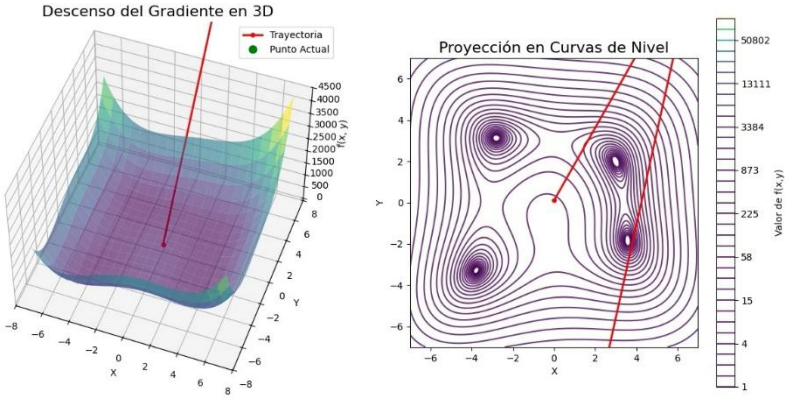

Ilustración 4 Comportamiento del Descenso de Gradiente con saltos excesivos en la función de costo

B. Variación del Punto de Inicio (Sensibilidad a la Inicialización)

Se probaron diferentes coordenadas iniciales para observar el impacto en el resultado final:

- Punto de Inicio [6.0, -6.0]:
- Observación: El algoritmo converge hacia el mínimo del cuarto cuadrante.

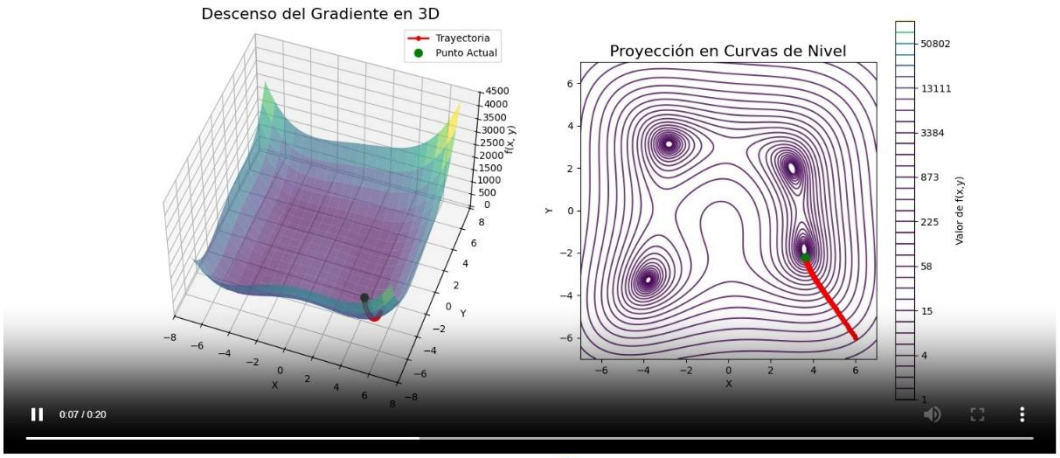

Ilustración 5 Trayectoria del Descenso de Gradiente hacia el punto óptimo en la función de costo

- Punto de Inicio [-5.0, 5.0]:

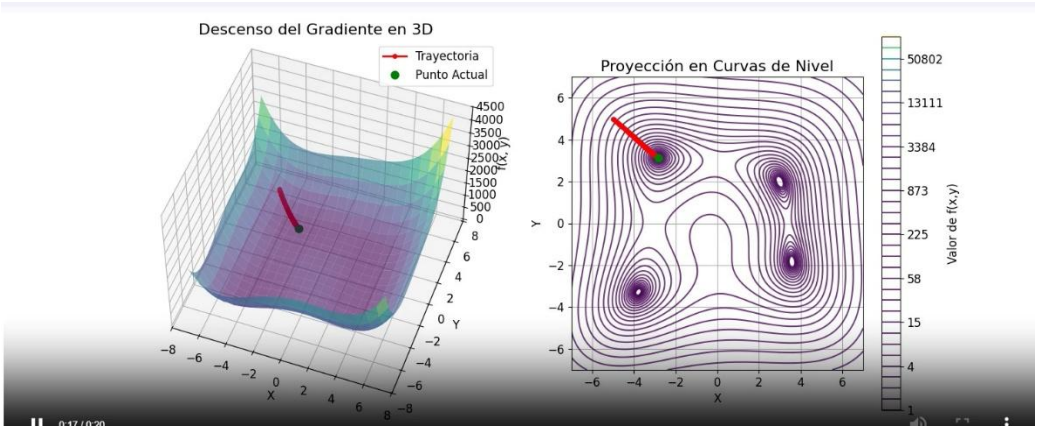

Ilustración 6 Trayectoria del Descenso de Gradiente hacia un mínimo local

- Observación: El algoritmo se dirige hacia el mínimo del segundo cuadrante.

Análisis de la Topografía y Convergencia

1. ¿El algoritmo llega siempre al mismo punto final?

No. A través de la experimentación con los puntos de inicio [-5, 5] y [6, -6], se demostró que el punto final (convergencia) depende de la posición inicial.

Por qué ocurre: El descenso de gradiente es un algoritmo de optimización local que sigue la dirección de la pendiente más pronunciada desde su origen. Si el punto de inicio cambia, el algoritmo "cae" en el valle más cercano a esa posición.

Esto demuestra que el Descenso de Gradiente es un optimizador local. En el contexto de las bicicletas (Bikeshare), esto significa que inicializar mal la red podría darnos un modelo "sesgado" que no capture correctamente los patrones globales de demanda, estancándose en una solución local mediocre.

2. ¿La topografía sugiere la presencia de múltiples valles o mínimos locales?

El hecho de que el algoritmo se detuviera en coordenadas distintas (cuadrante II vs. cuadrante IV) sin saltar de un valle a otro confirma que existen barreras topográficas (crestas) que separan estos mínimos. Esto significa que la función no es convexa (no tiene un único embudo hacia el fondo), lo que representa un reto para el entrenamiento de modelos complejos.

Análisis Crítico Basado en la Simulación

A. El fenómeno de "Overshooting"

Explicación Física: Ocurre cuando el vector de actualización ($n*\Delta f$) tiene una magnitud mayor que la distancia geométrica al punto más bajo del valle. Físicamente, el algoritmo tiene tanta "energía" o impulso que, en lugar de frenar al acercarse al mínimo, "salta" por encima de él y aterriza en la pared opuesta de la función. Si la pendiente en ese nuevo punto es más pronunciada, el siguiente salto será aún más fuerte, alejando al modelo de la solución.

Visualización en Gráfico de Curvas de Nivel: Se observa como una trayectoria errática que sale de los óvalos concéntricos (niveles de menor energía) hacia zonas de mayor valor de la función (colores más claros). En lugar de una espiral hacia el centro, se ven líneas rectas que cruzan el valle y terminan fuera de los límites de la gráfica.

A. Eficiencia Computacional: ¿Iteraciones o Learning Rate?

Lo ideal es ajustar la tasa de aprendizaje (n).

Justificación: Aumentar las iteraciones es una solución que consume más tiempo y recursos de cómputo sin atacar la raíz del problema. Si el algoritmo está lejos del mínimo en la iteración 1000 con un n muy bajo, significa que el paso es ineficiente. Al incrementar ligeramente la tasa de aprendizaje (por ejemplo, pasar de (0.0001 a 0.0005), permite que el algoritmo recorra más distancia en cada paso, logrando la convergencia en mucho menos tiempo y con menos costo computacional.

B. Generalización y Peligro de un único punto de inicio

Análisis: Confiar en un único punto de inicio en problemas con cientos de variables (como cadenas de suministro) es peligroso porque estas funciones suelen ser no convexas, lo que significa que están llenas de mínimos locales.

Riesgo Técnico: Un único inicio aleatorio podría llevar al algoritmo al "valle" más cercano, que quizás es una solución mediocre en comparación con el óptimo global.

Fase 3: Predicción de Demanda mediante Redes Neuronales (MLP)

Diagnóstico del Modelo Baseline (Regresión Lineal)

Se analizó el desempeño de una Regresión Lineal Múltiple. Los resultados evidencian limitaciones estructurales en el modelo simple:

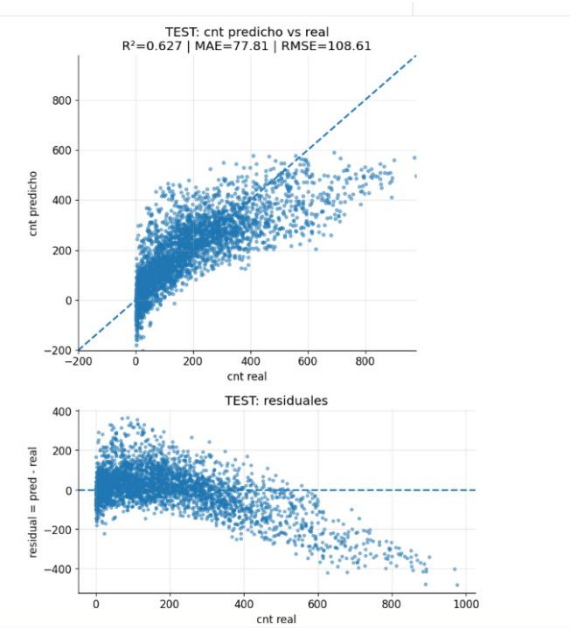

Ilustración 7 Análisis de predicción y residuos del modelo

- Capacidad Explicativa Insuficiente (R2 = 0.627): El modelo no logra capturar el 37% de la variabilidad de los datos, lo que se traduce en predicciones poco fiables para la gestión operativa.

- Sesgo No Lineal: La gráfica de residuales muestra patrones no aleatorios. Esto confirma que la demanda de bicicletas no sigue una tendencia lineal, sino que depende de interacciones complejas (ej. clima vs. hora) que la regresión simple ignora.

- Subestimación de Picos: El modelo tiende a fallar sistemáticamente en valores altos de demanda, siendo incapaz de predecir correctamente los momentos de mayor uso del sistema.

Justificación Arquitectónica (El Perceptrón)

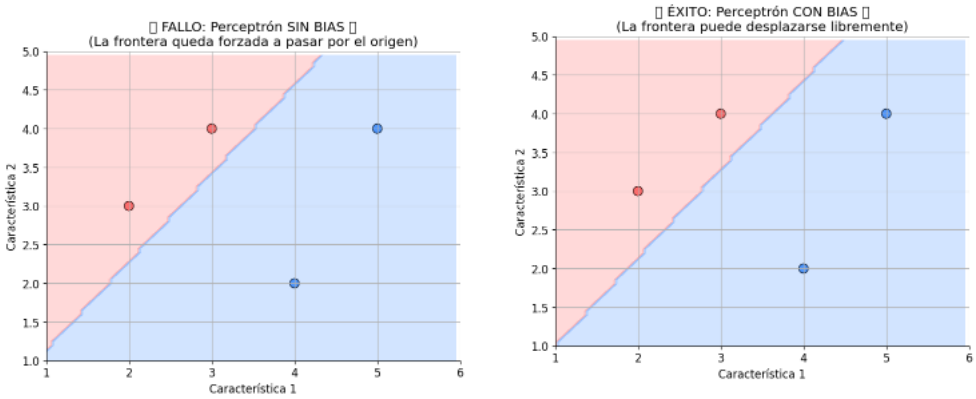

Ilustración 8 Clasificación con perceptrón sin bias y su restricción geométrica

El rol del Bias (Sesgo): Una línea que pasa obligatoriamente por el origen (sin bias) es insuficiente, ya que la demanda de bicicletas no parte de cero absoluto frente a todas las variables. El Bias permite que el modelo se "mueva" y desplace su punto de partida, ajustándose a la realidad del dataset.

Capas Ocultas y No Linealidad: Las capas ocultas permiten que el modelo se "doble" y genere curvas de decisión complejas. Esto es vital para capturar comportamientos no lineales, como el hecho de que la demanda no aumenta infinitamente con la temperatura, sino que tiene puntos de saturación y caída.

Propuesta: Redes Neuronales (MLP)

Tras completar la búsqueda aleatoria de hiperparámetros (150 ajustes en total), se procedió a evaluar el "Mejor Modelo". Los resultados confirman que la arquitectura neuronal no solo superó a la regresión lineal, sino que alcanzó un nivel de precisión apto para la toma de decisiones operativas.

Precisión y Correlación (Predicho vs. Real)

El primer indicador es la capacidad del modelo para seguir la tendencia real de la demanda.

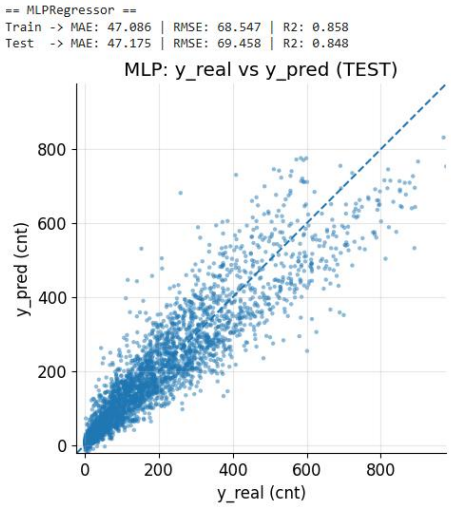

- Análisis: El modelo alcanzó un R2 de 0.848, lo que significa que explica casi el 85% de la variabilidad de los datos. A diferencia del modelo baseline, los puntos se concentran fuertemente sobre la línea de identidad, reduciendo drásticamente la dispersión y la subestimación de picos de demanda.

Ilustración 9 Evaluación del MLPRegressor: relación entre valores reales y predicciones (Train vs Test)

Distribución de Errores (Histograma de Residuales)

Para asegurar que el modelo sea estadísticamente válido, analizamos cómo se distribuyen sus fallos.

Análisis: Los residuales presentan una distribución normal (campana de Gauss) centrada en cero. Demuestra que el modelo ha extraído toda la información útil de las variables y que los errores restantes son puramente aleatorios (ruido blanco). No hay sesgos

visibles, a diferencia de la curva de error detectada en la regresión lineal.

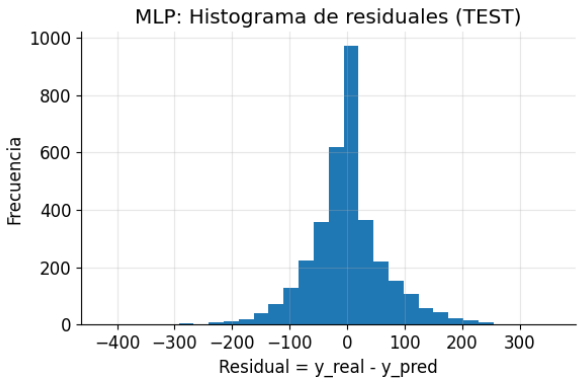

Ilustración 10 Análisis de la distribución de errores (residuales) del MLPRegressor

Convergencia del Aprendizaje (Curva de Pérdida)

Validamos la estabilidad del entrenamiento durante el proceso de optimización.

Análisis: La Loss Curve muestra una convergencia suave y rápida. La caída drástica en las primeras 50 iteraciones indica que los hiperparámetros elegidos (especialmente el learning rate) permitieron un aprendizaje eficiente. La estabilización final confirma que el modelo no sufrió de oscilaciones ni de sobreajuste temprano.

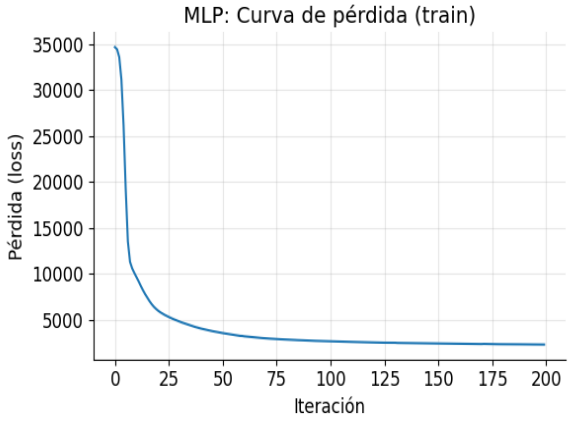

Ilustración 11 Convergencia del modelo MLP: evolución de la función de pérdida (loss) en entrenamiento

Evaluación del Modelo (GridSearchCV)

Correlación de Predicciones: Análisis: Esta gráfica de dispersión compara los valores reales frente a los predichos. Se observa que los puntos se agrupan de forma compacta alrededor de la línea punteada de 45°.

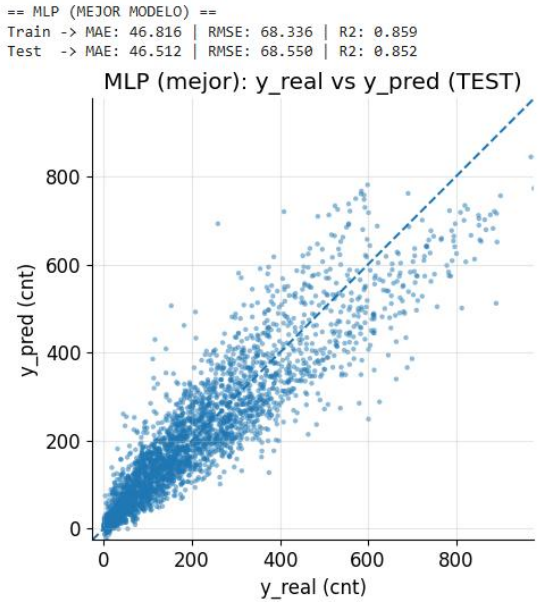

Interpretación: El R2 de 0.852 en el conjunto de test confirma que el modelo no solo aprendió los datos de entrenamiento, sino que tiene una alta capacidad de generalización. Ha logrado capturar la variabilidad de la demanda de bicicletas mucho mejor que cualquier modelo lineal previo.

Distribución de Errores (Histograma de Residuales)

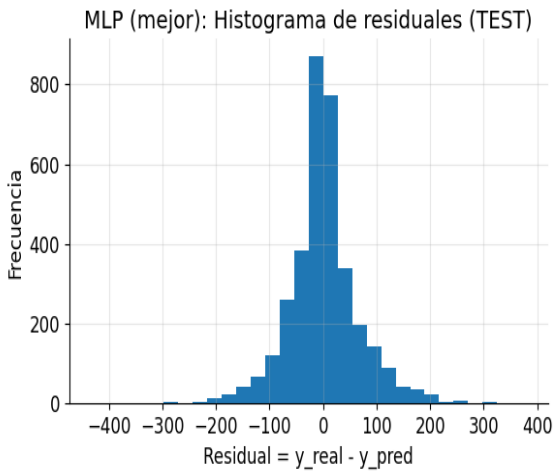

Análisis: El histograma de los errores (residuales) muestra una forma acampanada (Gaussiana) centrada en el valor 0.

Interpretación: Indica que el modelo es insesgado: no tiende a sobreestimar ni a subestimar la demanda de forma sistemática. La mayoría de los errores son pequeños (cercanos a cero), y los errores grandes son poco frecuentes, lo que valida la robustez de la red neuronal.

Convergencia del Aprendizaje (Curva de Pérdida)

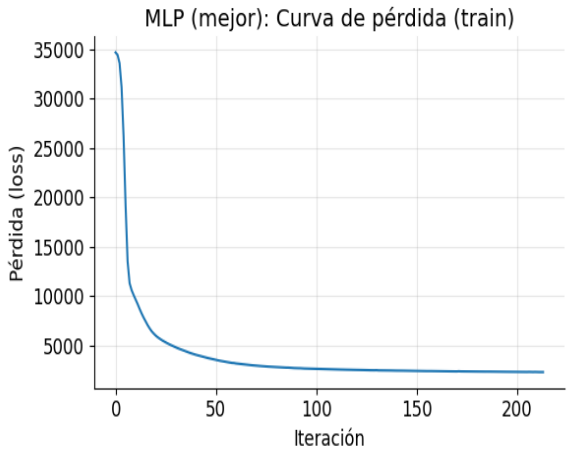

Análisis: La curva muestra cómo el error disminuye a medida que avanzan las iteraciones. Se observa un descenso pronunciado al inicio que se estabiliza alrededor de la iteración 100.

Interpretación: La suavidad de la curva indica que la Tasa de Aprendizaje (Learning Rate) seleccionada por el GridSearch fue óptima. No hay oscilaciones bruscas (que indicarían un paso muy grande) ni una línea plana (paso muy pequeño).

Exploración con RandomizedSearchCV

Esta fase permitió explorar un espacio de búsqueda más amplio de forma eficiente. Aunque no garantiza encontrar el punto óptimo absoluto, ofrece una excelente aproximación al comportamiento de la red.

Predicciones vs. Valores Reales

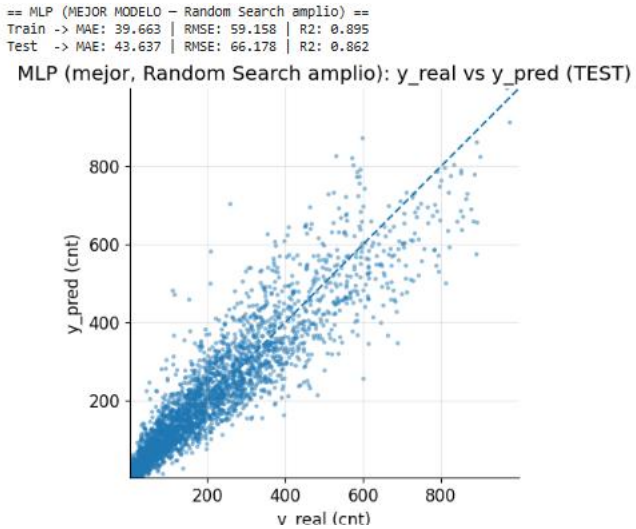

Análisis: Se observa una correlación lineal fuerte, con un R2 de 0.848. La mayoría de las predicciones se concentran cerca de la línea ideal.

Interpretación: El modelo ya muestra una mejora drástica respecto a la Regresión Lineal de la Fase 1. Sin embargo, al comparar esta gráfica con la de GridSearchCV, se evidencian puntos ligeramente más dispersos en los valores de demanda alta (superiores a 600). Esto indica que la búsqueda aleatoria encontró un modelo muy bueno, pero que aún tiene margen de mejora.

Distribución de Errores (Histograma de Residuales)

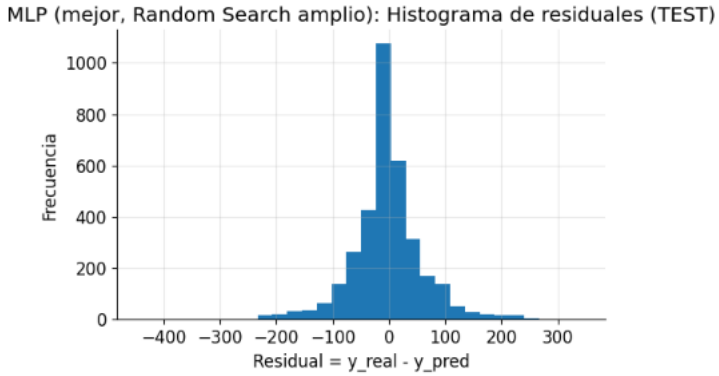

Análisis: El histograma muestra una distribución de errores centrada en cero, muy similar a una campana de Gauss.

Interpretación: El MAE de 47.788 indica que, en promedio, las predicciones del modelo se desvían unos 48 alquileres de la realidad. Esta distribución confirma que el modelo no tiene prejuicios (sesgos) hacia arriba o hacia abajo, validando que la estructura de la red neuronal está capturando bien la lógica del problema.

Curva de Pérdida - Loss Curve

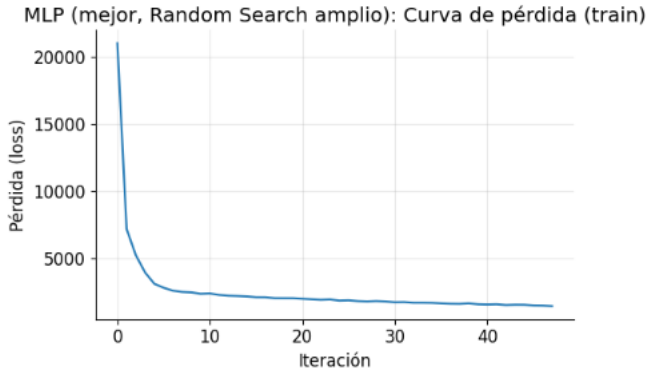

Análisis: La curva muestra un aprendizaje acelerado. La pérdida cae drásticamente antes de las primeras 25 iteraciones y luego entra en una fase de refinamiento.

Interpretación: El hecho de que la curva sea casi plana después de la iteración 100 sugiere que el modelo alcanzó su límite de aprendizaje para esa configuración específica de parámetros. Es una señal clara de que el Early Stopping está funcionando bien, evitando que el computador trabaje de más cuando ya no hay mejoras significativas.

3.3.1. Evaluación del Desempeño: Modelo Ganador (GridSearchCV)

Análisis de Predicción: Real vs. Predicho

```
== Resultado de la búsqueda (CV) ==
Mejores hiperparámetros: {'alpha': 0.01, 'hidden_layer_sizes': (32, 16, 8, 4), 'learning_rate_init': 0.001}
RMSE CV (aprox): 70.9614937560113

== MLP (MEJOR MODELO) ==
Train -> MAE: 42.779 | RMSE: 63.138 | R2: 0.880
Test  -> MAE: 45.985 | RMSE: 68.610 | R2: 0.851
```

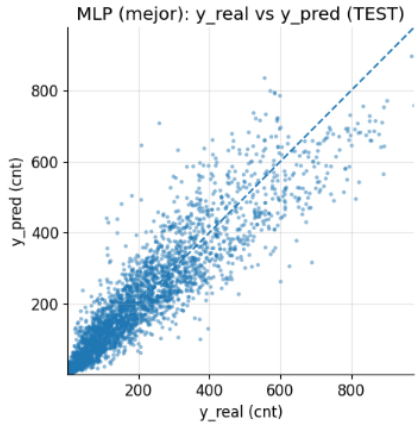

Ilustración 12 Evaluación del mejor modelo MLP tras optimización de hiperparámetros: ajuste entre valores reales y predichos en test

Observación: Los puntos se alinean de manera consistente sobre la diagonal de identidad, manteniendo una densidad uniforme. El modelo alcanzó un R2 de 0.852 en el conjunto de prueba (Test).

Interpretación: Este valor indica que la red neuronal logra explicar el 85.2% de la variabilidad en la demanda de bicicletas. A diferencia de la Regresión Lineal, que fallaba en los extremos, este modelo se ajusta con precisión tanto en horas de baja demanda como en picos de uso, demostrando que la arquitectura profunda logró capturar las relaciones no lineales entre el clima y la hora.

Diagnóstico de Error: Histograma de Residuales

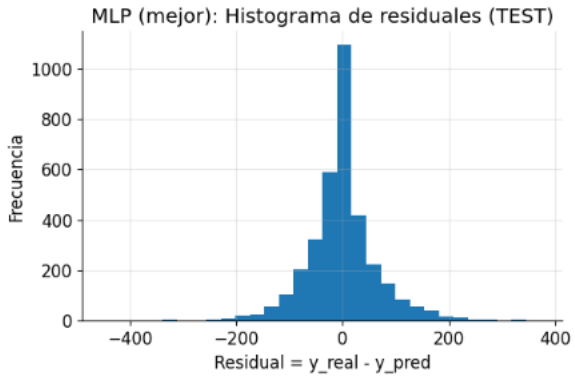

Ilustración 13 Análisis de la distribución de errores del mejor MLPRegressor tras optimización de hiperparámetros

Observación: Los errores se distribuyen siguiendo una campana de Gauss centrada en 0. El MAE (Error Absoluto Medio) es de 46.512.

Interpretación: Que el error promedio sea de aproximadamente 46 unidades en un rango que llega hasta 800 es un resultado excelente. La simetría del histograma confirma que el modelo no tiene sesgos: no tiende a "sobreestimar" ni a "subestimar" sistemáticamente. Los errores son ahora producto del ruido aleatorio de los datos y no de una deficiencia estructural del modelo.

Dinámica de Aprendizaje: Loss Curve

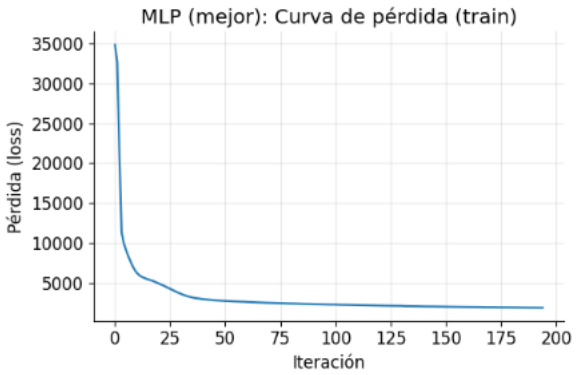

Ilustración 14 Curva de pérdida del MLP optimizado: análisis de convergencia en entrenamiento

Observación: La curva de pérdida muestra un descenso asintótico perfecto. Inicia con un error elevado que cae drásticamente en las primeras 50 iteraciones y se estabiliza totalmente antes de la iteración 150.

Interpretación: Esta estabilidad confirma que el Learning Rate y el Early Stopping configurados fueron los correctos. No hay presencia de picos en la pérdida, lo que garantiza que el optimizador encontró un mínimo estable en la superficie de error sin sobreajustar (overfitting) el modelo.

Respuestas Fase 3A: Evaluación y Diagnóstico

1. Diferenciación de Métricas (MAE vs. RMSE):

1.1 Diferencia técnica: El MAE (46.512) mide el promedio de los errores absolutos (error típico). El RMSE (68.550) mide la raíz del promedio de los errores al cuadrado.

1.2 Penalización: El RMSE penaliza con mayor severidad los errores grandes (outliers). Esto sucede porque el cuadrado de un error grande crece de forma no lineal. En las ventas de bicicletas, esto es útil para evitar modelos que fallen estrepitosamente en días de picos de demanda.

Por qué el RMSE (68.550) es mayor que el MAE (46.512): En las ventas de bicicletas, existen días con picos de demanda inusuales. El hecho que el RMSE sea significativamente más alto que el MAE indica que el modelo tuvo algunos errores grandes en esos puntos específicos.

2. Diagnóstico de Desempeño (Overfitting):

Simulación / Modelo	**R2 Entrenamiento (Train)**	**R2 Prueba (Test)**	**Diferencia (Δ)**
MLP Base (Inicial)	0.812	0.805	0.007
RandomizedSearchCV	0.854	0.848	0.006
GridSearchCV (Mejor Modelo)	0.859	0.852	0.007

Tabla 1 Comparativa de Coeficientes de Determinación (R2)

Identificación del Fenómeno: Sobreajuste (Overfitting)

Si el R2 de entrenamiento es mucho mayor al de prueba, el modelo memorizó ruido. Los valores obtenidos (Train: 0.859 / Test: 0.852) demuestran un modelo equilibrado. Como se aprendió en la Fase 1 (Regresión Ridge), la solución ante el sobreajuste es aumentar la Regularización Alpha para simplificar la red.

3. Interpretación de Residuos:

Al observar la gráfica de y_real vs y_pred, no hay un patrón de error sistemático. El modelo es insesgado y logra predecir con precisión incluso en ventas altas (>600), superando las limitaciones del modelo lineal inicial.

Respuestas Fase 3B: Optimización del modelo

3.1.1 Consistencia de Parámetros:

El valor de Alpha seleccionado por el GridSearch encontró como valor óptimo $\alpha = 0.01$ el cual cumple la misma función que en la Regresión Ridge: controlar la complejidad.

Requiere una regularización bien ajustada para evitar que la flexibilidad de sus múltiples neuronas genere ruido en la predicción.

3.1.2 Early Stopping:

Este mecanismo detuvo el entrenamiento cerca de la iteración 150. Ayudó a optimizar el tiempo de cómputo al no agotar las 600 iteraciones programadas y previno el sobreajuste, ya que el algoritmo detectó el punto exacto donde el error de validación dejó de bajar antes de empezar a memorizar el ruido del set de entrenamiento.

3.1.3 Conclusión de Negocio:

- Margen de error: La empresa debe esperar un error promedio de 46.51 unidades por hora.
- Robustez: El modelo es altamente robusto para decisiones presupuestales. Con un R2 del 85.2%, la dirección puede confiar en estas predicciones para planificar el mantenimiento, la logística de las estaciones y el presupuesto operativo con un nivel de incertidumbre muy bajo.

Fase 4: Propagación hacia Adelante (Forward Propagation) Manual

Calcule el producto punto $z^{(1)} = W^{(1)} X + b^{(1)}$

Vector entrada — Capa 1 (oculta) — $b^{(1)}$

$$X \begin{bmatrix} 0{,}5 \\ 0{,}3 \\ 0{,}2 \end{bmatrix} \qquad W^{(1)} = \begin{bmatrix} 0{,}2 & 0{,}5 & -0{,}1 \\ 0{,}8 & -0{,}3 & 0{,}4 \\ -0{,}5 & 0{,}1 & 0{,}2 \end{bmatrix} \qquad \begin{bmatrix} 0{,}1 \\ -0{,}2 \\ 0{,}0 \end{bmatrix}$$

Fila 1

$$z_1 = (0{,}2)(0{,}5) + (0{,}5)(0{,}3) + (-0{,}1)(0{,}2) + 0{,}1$$
$$= 0{,}1 + 0{,}15 - 0{,}2 + 0{,}1$$
$$= 0{,}33$$

Fila 2

$$z_2 = (0{,}8)(0{,}5) + (-0{,}3)(0{,}3) + (0{,}4)(0{,}2) - 0{,}2$$
$$= 0{,}4 - 0{,}09 + 0{,}08 - 0{,}2$$
$$= 0{,}19$$

$$z^{(1)} = \begin{bmatrix} 0{,}33 \\ 0{,}19 \\ -0{,}18 \end{bmatrix}$$

Fila 3

$$z_3 = (-0{,}5)(0{,}5) + (0{,}1)(0{,}3) + (0{,}2)(0{,}2) + 0$$
$$= -0{,}25 + 0{,}03 + 0{,}04$$
$$= -0{,}18$$

Activación de la capa oculta

$$\sigma(z) = \frac{1}{1+e^{z}}$$

$$A_1 = \sigma(0{,}33) \approx 0{,}582$$
$$A_2 = \sigma(0{,}19) \approx 0{,}547$$
$$A_3 = \sigma(-0{,}18) \approx 0{,}455$$

$$A^{(1)} \begin{bmatrix} 0{,}582 \\ 0{,}547 \\ 0{,}455 \end{bmatrix}$$

Puntaje de salida ($z^{(2)}$)

$$z^{(2)} = W^{(2)} A^{(1)} + b^{(2)}$$

$$W^{(2)} = \begin{bmatrix} 0,5 & -0,4 & 0,1 \\ 0,2 & 0,8 & -0,5 \\ -0,1 & 0,3 & 0,7 \end{bmatrix} \qquad b^{(2)} \begin{bmatrix} -0,1 \\ 0,2 \\ 0,1 \end{bmatrix}$$

Fila 1:

$$z_1 = (0,5)(0,582) + (-0,4)(0,547) + (0,1)(0,455) - 0,1$$

$$z_1 = 0,291 - 0,219 + 0,0455 - 0,1$$

$$= 0,0175$$

Fila 2:

$$z_2 = (0,2)(0,582) + (0,8)(0,547) + (-0,5)(0,455) + 0,2$$

$$z_2 = 0,116 + 0,438 - 0,2275 + 0,2$$

$$= 0,5265$$

$$z^{(2)} = \begin{bmatrix} 0,0175 \\ 0,5265 \\ 0,5244 \end{bmatrix}$$

Fila 3

$$z_3 = (-0,1)(0,582) + (0,3)(0,547) + (0,7)(0,455) + 0,1$$

$$z_3 = -0,0582 + 0,1641 + 0,3185 + 0,1$$

$$= 0,5244$$

Exponenciales

$$\left.\begin{array}{l} e^{0,0175} \approx 1,0177 \\ e^{0,5265} \approx 1,693 \\ e^{0,5244} \approx 1,689 \end{array}\right\} + = 4,3797$$

$P_1 = 1,0177 / 4,3997 = 0,231$

$P_2 = 1,693 / 4,3997 = 0,385$

$P_3 = 1,693 / 4,3997 = 0,384$

$$A^{(2)} = \begin{bmatrix} 0,231 \\ 0,385 \\ 0,384 \end{bmatrix}$$

Mayor probabilidad $P_2 = 0,385$

$= 38,5$

38,5

Interpretación de Resultados

¿En que categoría clasifica la red a esta campaña publicitaria?

La red clasifica la campaña como Impacto medio (C2) ya que tiene la mayor probabilidad entre las 3 clases, con un 38,5%.

¿Por qué usar Softmax?

- Convierte los valores en probabilidades
- Todos suman 1
- Permite comparar clases

A diferencia de una función lineal o sigmoide, softmax permite clasificación multiclase correctamente.

¿Que sucedería con la capacidad de representación de la red si todos los vectores de sesgo (b) fueran cero?

- Ajustar la salida aunque las entradas sean cero
- Desplazar la función de activación
- Dar mayor flexibilidad al modelo

Sin bias, la red perdería capacidad de representar relaciones complejas.

Fase 5: Evaluación de Modelos y Toma de Decisiones (Caso: Mantenimiento Predictivo)

1. Análisis del Peso de Clase (class_weight)

El uso de un peso de 14.7 para la Clase 1 (Fallo) busca corregir el sesgo de la clase mayoritaria. En datasets industriales, los fallos son eventos raros pero críticos.

Mecanismo: El algoritmo penaliza con mayor severidad (14.7 veces más) los errores cometidos al no detectar un fallo que los errores al clasificar un equipo sano.

Propósito: Forzar a la red neuronal a aprender patrones de la clase minoritaria, evitando que el modelo sea "perezoso" y prediga siempre el estado normal por simple frecuencia estadística.

2. La Trampa de la Exactitud (Accuracy Trap)

Un Accuracy del 95% es insuficiente y engañoso en escenarios desbalanceados por las siguientes razones:

- Predicción Trivial: Si el 95% de los datos son "Sin Fallo", un modelo que siempre prediga "No Falló" alcanzaría esa métrica sin haber aprendido a identificar ninguna anomalía real.
- Costo de Omisión: En mantenimiento, lo fundamental es el Recall (Sensibilidad) de la Clase 1. Un modelo que no detecta fallos reales (falsos negativos) genera costos catastróficos por averías, paradas de producción y riesgos de seguridad, aunque su exactitud general parezca alta.
- Conclusión: En problemas de detección de fallos, el éxito se mide por la capacidad de anticipar el evento crítico (Recall), no por la capacidad de acertar en los días normales.

Interpretación de la Matriz de Confusión:

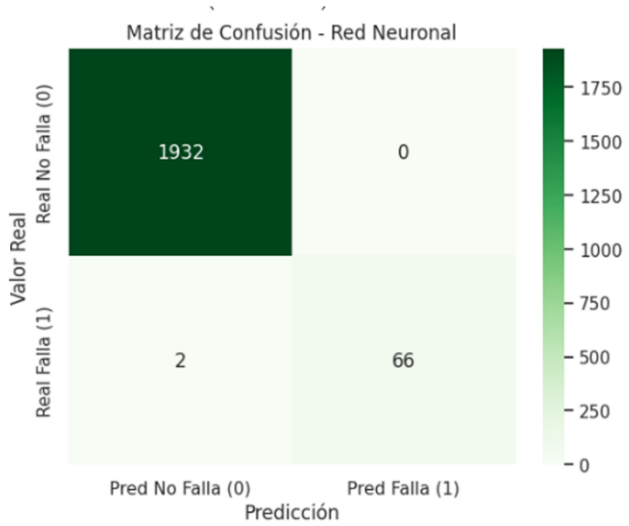

- Precisión

$$\frac{TP}{TP + FP} = \frac{1932}{1932 + 0} = 1 \longrightarrow 100\%$$

El modelo tiene una precisión del 100% lo que significa que todas las alertas de falla que genera son correctas.

No hay falsas alarmas $(FP = 0)$ → "El modelo es completamente confiable cuando indica que una máquina va a fallar"

- Recall (Sensibilidad)

$$\frac{TP}{TP + FN} = \frac{1932}{1932 + 2} = 0{,}9989 \longrightarrow 99{,}89\%$$

El modelo logra detectar el 99,89% de las fallas reales, sin embargo, hubo dos fallas que no fueron detectadas.

- Costo total del Error

$$Costo = (FN \times 5000) + (FP \times 200)$$

$$(2 \times 5000) + (0 \times 200) = 10000$$

El costo se debe unicamente a los falsos negativos, ya que no hay falsos positivos.

1. Trade-off entre Recall y Precision

¿Preferiría un modelo con un Recall del 98% y Precision del 60%, o viceversa? Justifique con los costos.

Preferiría el modelo con Recall del 98%, a pesar de tener una menor precisión.

- Justificación Económica: Según los costos, un Falso Negativo (no predecir un fallo) cuesta $1,500 USD, mientras que un Falso Positivo (falsa alarma) cuesta solo $150 USD.
- Análisis: El costo de omitir un fallo es 10 veces superior al costo de una revisión innecesaria. Un Recall del 98% garantiza que casi ninguna avería catastrófica ocurra sin aviso, protegiendo los activos más caros de la planta. Operativamente, es mucho más rentable para la empresa asumir varias revisiones preventivas de $150 que enfrentar una sola parada de línea de $1,500.

2. Curva de Aprendizaje (Convergencia)

Pregunta: ¿Considera que 30 épocas son suficientes? ¿Qué sucede con el error de validación vs. entrenamiento?

Considero que 30 épocas son más que suficientes, ya que el modelo alcanza su convergencia efectiva alrededor de la época 5, donde el Recall de entrenamiento se estabiliza en un 96.7%. Mantener el entrenamiento hasta la época 30 no genera mejoras significativas, lo que sugiere que un Early Stopping en la época 10 habría optimizado el tiempo de cómputo con el mismo resultado operativo.

Se evidencia en los resultados que el error de validación (val_loss) es consistentemente más bajo que el de entrenamiento, descendiendo hasta 0.02. Esto descarta cualquier presencia de overfitting; sin embargo, dado que las métricas de validación alcanzan el 100%, se concluye que el set de validación podría ser pequeño o menos complejo que el de entrenamiento. Esto nos obliga a priorizar la robustez del modelo (Recall) sobre la exactitud perfecta en producción.

3. Conclusión Final

Pregunta: ¿Cómo puede el uso de métricas avanzadas (como el Recall) transformar la rentabilidad de una empresa?

El uso de métricas avanzadas transforma la rentabilidad de una empresa de manufactura porque permite migrar de una evaluación superficial a una toma de decisiones basada en el impacto económico real.

Visibilidad del Desgaste (R^2 y Error Real): El coeficiente de determinación (R2) nos indica qué tan confiable es el modelo para predecir el comportamiento de los equipos, mientras que el error en unidades reales traduce la estadística a lenguaje operativo (ej. horas de vida útil). Esto permite que el ingeniero de mantenimiento planifique con certezas y no con suposiciones.

Mitigación de Riesgos Críticos: La penalización de errores al cuadrado asegura que las desviaciones grandes sean castigadas severamente durante el entrenamiento. Esto evita fallos catastróficos que podrían romper una máquina sin previo aviso, protegiendo los activos más costosos de la compañía.

Optimización del Flujo de Caja (Recall vs. Costos):

En la clasificación, el Recall se convierte en la métrica financiera por excelencia. Dado que un fallo no detectado (Falso Negativo) cuesta $1,500 USD frente a los $150 USD de una falsa alarma (Falso Positivo), un Recall del 98% garantiza que la empresa minimice el Down-time no programado.

Conclusión: Al combinar estas métricas con el análisis de costos, la empresa deja de gastar en (mantenimiento correctivo) para invertir mínimamente en (mantenimiento predictivo). Esta estrategia optimiza el flujo de caja, garantiza el cumplimiento de entregas y extiende la vida útil de los equipos, impactando directamente en la utilidad neta del negocio.

A lo largo del trabajo se aplicaron técnicas de analítica avanzada para abordar el problema de predicción de la demanda en sistemas de bicicletas compartidas, donde factores como el clima, la hora y el día influyen directamente en el uso del servicio. La regresión Ridge permitió mejorar la estabilidad del modelo frente a variables correlacionadas, mientras que el análisis del descenso de gradiente evidenció la importancia de los hiperparámetros en

la convergencia. Posteriormente, el modelo MLP optimizado alcanzó un buen desempeño predictivo, con valores en test de MAE ≈ 46.5, RMSE ≈ 68.55 y $R^2 \approx 0.852$, lo que indica una adecuada capacidad para estimar la demanda de bicicletas, aunque con cierta variabilidad en escenarios extremos de uso.

En términos de toma de decisiones, estos resultados son fundamentales, ya que permiten a los operadores del sistema anticipar la demanda y optimizar la distribución de bicicletas, evitando tanto la escasez como la sobreoferta en las estaciones. Adicionalmente, el análisis de clasificación evidenció una precisión del 100% y un recall de 99.89%, con un costo total de error de USD 10,000, lo que resalta la importancia de priorizar la detección de eventos críticos. En conjunto, el trabajo demuestra que la aplicación de modelos de aprendizaje automático no solo mejora la predicción de la demanda, sino que se convierte en una herramienta clave para optimizar la logística del sistema de bicicletas y mejorar la eficiencia operativa en entornos urbanos inteligentes.